

T.C.
KOCAELİ ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLİŞİM SİSTEMLERİ MÜHENDİSLİĞİ

**YÜZ PARAMETRELERİ YARDIMI İLE İNSANLARIN YAŞ,
CİNSİYET ve ETNİK KÖKENLERİNİN BELİRLENMESİ**

PROJE A TEZİ

EFECAN DEMİR

AZİZ GÜLTEKİN

DANIŞMAN

DOÇ. DR. HALİL YİĞİT

OCAK 2022

T.C.
KOCAELİ ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLİŞİM SİSTEMLERİ MÜHENDİSLİĞİ

**YÜZ PARAMETRELERİ YARDIMI İLE İNSANLARIN YAŞ,
CİNSİYET ve ETNİK KÖKENLERİNİN BELİRLENMESİ**

PROJE A TEZİ

EFECAN DEMİR

AZİZ GÜLTEKİN

DANIŞMAN

DOÇ. DR. HALİL YİĞİT

OCAK 2022

ÖN SÖZ ve TEŞEKKÜR

Proje A çalışmalarımız boyunca gösterdiği her türlü destek ve yardımdan dolayı değerli Doç. Dr. Halil Yiğit hocamıza teşekkürlerimizi sunarız.

OCAK 2022

EFECAN DEMİR

AZİZ GÜLTEKİN

ÖZET

YÜZ PARAMETRELERİ YARDIMI İLE İNSANLARIN YAŞ, CİNSİYET ve ETNİK KÖKENLERİNİN BELİRLENMESİ

Demir, Efecan

Gültekin, Aziz

Danışman: Doç. Dr. Halil Yiğit

Ocak, 2022.

İnsanların yaşam biçimleri, etnik kökenleri, hareketlerini ve tercihlerini etkilemektedir. Teknolojinin gelişmesi ile insanların tanımlanması ve sınıflandırılması güvenlik, pazarlama, satış gibi farklı alanlarda daha çok kullanılmaya başlamıştır. İnsan yüzünün karakteristik özellikleri sınıflandırma için gerekli parametreleri barındırmaktadır. Bu parametreler ile sınıflandırma işlemi farklı teknikler kullanılarak yapılmaktadır. Bu çalışmada derin öğrenme teknikleri kullanılarak, insanları etnik kökenleri, yaşları ve cinsiyetlerine göre sınıflandıran bir sistem yapılmıştır. Sisteme gelen fotoğraf, görüntü işleme ve derin öğrenme teknikleri ile işleme sokulup yüz tanıma, öznitelik çıkarma, hizalama, ve sınıflandırma gibi aşamalardan geçecektir.

Anahtar Kelimeler: Yüz tanıma, etnik köken, yaş, cinsiyet, görüntü işleme.

ABSTRACT

DETERMINING PEOPLE'S AGE, GENDER AND ETHNIC ORIGINS WITH THE HELP OF FACE PARAMETERS

Demir, Efecan

Gültekin, Aziz

Supervisor: Doç. Dr. Halil Yiğit

January, 2022.

People's lifestyles, ethnic origins affect their movements and preferences. With the development of technology, the identification and classification of people has begun to be used more in different areas such as security, marketing and sales. The characteristic features of the human face contain the necessary parameters for classification. With these parameters, the classification process is carried out using different techniques. In this study, a system that categorizes people according to their ethnic origins, age and gender has been developed using deep learning techniques. The photo coming to the system will be processed with image processing and deep learning techniques and will go through stages such as face recognition, feature extraction, alignment, and classification.

Keywords: Face recognition, ethnicity, age, gender, image processing.

İÇİNDEKİLER

Önsöz.....	3
Özet.....	4
Abstract.....	5
İçindekiler	6
Şekiller Listesi.....	7
1. Bölüm, Giriş.....	9
2. Bölüm, Temel Bilgiler.....	11
2.1 Makine Öğrenmesi.....	11
2.1.1 Gözetimli Öğrenme.....	11
2.1.2 Gözetimsiz Öğrenme.....	12
2.1.3 Takviyeli Öğrenme.....	12
2.2 Yapay Sinir Ağları.....	13
3. Bölüm, Yapılan Çalışmalar.....	15
3.1 UTKFace Veri Analizi ve Model Oluşturma.....	15
3.2 Modellerin Uygulamaya Geçirilmesi.....	26
Kaynaklar.....	31
Özgeçmiş ve İletişim Bilgileri.....	32

ŞEKİLLER LİSTESİ

Şekil 1:Sinir Ağları ve Nöron Yapısı.....	13
Şekil 2: Nöron Karar Mekanizması.....	14
Şekil 3: Verilerin Tanımlanması.....	15
Şekil 4: Dataset döndürülmesi ve gösterimi.....	15
Şekil 5: Irk yapısı inşası.....	16
Şekil 6: Cinsiyet yapısı inşası.....	16
Şekil 7: Yaş yapısı inşası.....	17
Şekil 8: Bileşenleri modelleme.....	17
Şekil 9: Oluşturulan yapının modellenmesi.....	18
Şekil 10: Model içerisinde bulunan ırk dağılımı.....	19
Şekil 11: Model içerisinde bulunan cinsiyet dağılımı.....	19
Şekil 12: Model içerisinde bulunan yaş dağılımı.....	20
Şekil 13: Model eğitimi için parametre girişi.....	21
Şekil 14: Model eğitimi kayıt ve epoch başlatma.....	21
Şekil 15: Etnik Kökenlerin Doğruluğu.....	22
Şekil 16: Ortalama mutlak hata (Yaş).....	22
Şekil 17: Genel Kayıp.....	23
Şekil 18: Irk f1-score ve accuracy değerleri.....	23
Şekil 19: Cinsiyet f1-score ve accuracy değerleri.....	24
Şekil 20: Yaş R2 değeri.....	24
Şekil 21: Tahminlerin çalıştırılmış hali.....	25
Şekil 22: Cinsiyet model tanımlanması.....	26
Şekil 23: Yaş model tanımlanması.....	26
Şekil 24: DNN (Derin Sinir Ağı) model mimarisine entegrasyonu.....	26

Şekil 25: OpenCV import edilmesi ve kullanımı.....	26
Şekil 26: OpenCV ve DeepFace import edilmesi.....	27
Şekil 27: Resim ön işleme komutu.....	27
Şekil 28: Model tanımlama.....	27
Şekil 29: Veri depolama için oluşturulmuş liste.....	28
Şekil 30: Yaş ve cinsiyet aralıkları belirlenmesi.....	28
Şekil 31: Yaş, cinsiyet ve etnik köken yazdırma.....	28
Şekil 32: Metni fotoğrafın üzerine yazdırma.....	29
Şekil 33: İlgili çıktının alınması.....	29
Şekil 34: Video görüntü yakalama kod bölümü.....	30
Şekil 35: Video görüntü yakalama çıktısı.....	30

BÖLÜM I

GİRİŞ

Yüz tanıma sistemleri uzun zamandır teknoloji firmalarının ve akademik çalışmaların odak noktasındadır. Yıllar içerisinde bir çok farklı teknik kullanılmış sistemler geliştirilmiştir. Teknolojinin ilerlemesi, insan tanıma performanslarının artması bu sistemleri daha popüler hale getirmiştir. Örneğin, akıllı telefonlar veya dizüstü bilgisayarlar gibi yaygın aygıtlarda, kimlik doğrulama için yüz tanıma uygulayarak parola, kaydırma deseni gibi geleneksel tanıma teknolojilerinin yerine yeni sistemler entegre edildi. Günümüzde kullanılan gelişmiş güvenlik kamerası sistemlerinde izinli ve izinsiz girişleri takip etmek için yüz tanıma sistemleri kullanılmaktadır. [1] Yüz tanıma uygulamaları kimlik yönetiminin ötesinde, kişisel veri toplama kapasitesi sayesinde bir resimden yaş, ırk, cinsiyet gibi bilgileri toplama fırsatı sunar. Irk, aynı türe ait bireylerin oluşturduğu topluluklardır. Sadece aynı türe ait olmalarının yanında, bireyleri belli başlı morfolojik ve genetik özellikleri ortak olarak birbirinde barındırabilirler. Örnek vermek gerekirse Afrika'da yaşayan bireylerin ten renklerinin siyah, Asya'da yaşayan bireylerin gözlerinin çekik olması gibi belli başlı ön plana çıkan keskin ortak özellikleri vardır. Bu çalışmanın amacı son teknolojik gelişmeler ışığında en yeni teknikler kullanılarak insan fotoğraf ve videolar üzerinden cinsiyet, yaş ve ırk sınıflandırması yapan bir sistem oluşturmaktır.

Son yıllarda cinsiyet tahmini uygulamaları çeşitli teknolojilerle karşımıza çıkmaktadır. En bilinen örneklerinden biri olan Microsoft'un fotoğraflar üzerinden yaş ve cinsiyet tahmini yapan internet sitesi "How Old Do I Look?" oldukça popüler olarak kullanılmaktadır. Fotoğraflardaki yüzleri algılayan, kişilerin cinsiyetini tahmin eden ve yaşını söyleyen site eğlence amaçlı kullanılmaktadır. Bir diğer önemli örnek ise; Xiaomi Mi 6'nın ön yüzünde 8 mega piksel çözünürlüklü, otomatik yüz güzelleştirme filtreli ve yapay zekâyı kullanarak cinsiyet ve yaş tahmini yapabilen bir kamerasının bulunuyor olmasıdır. Bu uygulama örnekleri çoğaltılabilir ve sosyal medya kullanan toplum yapısının artmasıyla yaş ve cinsiyet tahminine ilginin artacağı öngörülebilir. Bu çalışmada, büyük veri (big data) ve hayatımızı kolaylaştıran derin öğrenme ağ yapısını kullanarak, veri artırma yöntemiyle

çoğaltılan sentetik verili fotoğraflardan cinsiyet tahmini yapan modeller kullanılmıştır. Çalışmanın amacı, derin öğrenme algoritmalarını kullanarak, mağazalarda ürünlerle ilgilenen insanların, bir mağazada alışveriş yapmayı tercih eden insanların, Alışveriş merkezlerindeki müşterilerin, sosyal medya platformlarındaki kullanıcıların, siyasilerin mitinglerindeki kişilerin başta olmak üzere, görüntüleri üzerinden cinsiyet tahmini demografisini tespit etmeye yardımcı olacak bilgiler ve yöntemler sunmaktır. Aynı zamanda veri sayısı artırmanın başarıma olan etkisi vurgulanmaktadır. Bu amaçla çalışmaya uygun bir veri seti hazırlanmıştır. Veri seti kadın(female) ve erkek(male) olmak üzere 2 sınıfa ayrılmış ve her görüntü cinsiyete göre ve yaş bilgisine göre etiketlenmiştir. Derin öğrenme algoritmalarından VGG-16 kullanarak yapılan bir çalışmada yaş tahminlemek için de Vikipedi veri setinden faydalanılmıştır. Python dilinde program kodları yazılıp derin öğrenmede çeşitli kütüphaneler kullanılmıştır ve cinsiyet veri setleri üzerinden gerekli tahminler yapılmıştır [8].

Yüz tanıma sistemleri uzun zamandır teknoloji firmalarının ve akademik çalışmaların odak noktasındadır. Yıllar içerisinde bir çok farklı teknik kullanılmış sistemler geliştirilmiştir. Teknolojinin ilerlemesi, insan tanıma performanslarının artması bu sistemleri daha popüler hale getirmiştir. Örneğin, akıllı telefonlar veya dizüstü bilgisayarlar gibi yaygın aygıtlarda, kimlik doğrulama için yüz tanıma uygulayarak parola, kaydırma deseni gibi geleneksel tanıma teknolojilerinin yerine yeni sistemler entegre edildi. Günümüzde kullanılan gelişmiş güvenlik kamerası sistemlerinde izinli ve izinsiz girişleri takip etmek için yüz tanıma sistemleri kullanılmaktadır. [1] Yüz tanıma uygulamaları kimlik yönetiminin ötesinde, kişisel veri toplama kapasitesi sayesinde bir resimden yaş, ırk, cinsiyet gibi bilgileri toplama fırsatı sunar. Irk, aynı türe ait bireylerin oluşturduğu topluluklardır. Sadece aynı türe ait olmalarının yanında, bireyleri belli başlı morfolojik ve genetik özellikleri ortak olarak birbirinde barındırabilirler. Örnek vermek gerekirse Afrika'da yaşayan bireylerin ten renklerinin siyah, Asya'da yaşayan bireylerin gözlerinin çekik olması gibi belli başlı ön plana çıkan keskin ortak özellikleri vardır. Yüz tanıma sistemleri topladığı kişisel ve ortak özellikler sayesinde reklam verenlere pazarlama kampanyalarını kişiselleştirme olanağı sağlar [2].

BÖLÜM II

TEMEL BİLGİLER

2.1 MAKİNE ÖĞRENMESİ

Makine öğrenmesi belli başlı algoritma ve istatistiksel modellerin kullanılarak bilgisayar sistemlerinin kendi başlarına aksiyon almalarını sağlama eylemidir. Bilgisayar sistemi bu aksiyonları bazı çıkarımlar yaparak veya bazı kalıp girdileri tanıyarak eylemlerle eşleştirir.

2.1.1 GÖZETİMLİ ÖĞRENME

Gözetimli öğrenme eğitim verisi olarak adlandırılan bir veri kümesinin üzerine matematiksel model oluşturma işlemidir. Gözetimli öğrenmede eğitim verisi içerisindeki her bir girdiye karşılık gelen, beklentiyi karşılayan bir çıktı bulunur. Burada girdileri çıktılara eşleyen fonksiyon matematiksel modelin algoritma karşılığıdır. Eğitim işleminin yapılacağı makine her bir girdi için çıktıyı alır ve bu çıktıdan doğrulama işlemi yaparak hata payını hesaplar. Hata payı, hata düzeltme işleminde kullanılacak algoritmaya verilir ve model üzerinde gerekli düzenlemeler yapılır. Bu işlem eğitim verisindeki tüm girdiler için tekrarlanır ve istatistiksel modelin başarı ölçüsü kabul edilebilir düzeyde ise model tamamlanmış demektir.

2.1.2 GÖZETİMSİZ ÖĞRENME

Gözetimsiz öğrenme bilgisayar sisteminin eğitim datası olmadan çıkarımlar yapmasına dayanan bir makine öğrenmesi türüdür. Bu türde model önce birbirine benzeyen girdileri gruplar ve daha sonra bu gruplanmış veri türünün dışına çıkan girdilerde veya bu veri türüne benzer girdilerde aksiyon alır.

Gözetimsiz öğrenmenin zorlukları;

- Gözetimsiz öğrenmede örnek bir veri kümesi ve öğrenme yöntemi olmadığı için büyük veride daha yavaş çalışmaktadır.
- Ortaya çıkan modelin doğru kararlar verdiğini deneme ihtiyacı bulunmaktadır.

Zorluklara rağmen gözetimsiz öğrenmenin tercih sebepleri;


- Büyük veride etiketleme ve gruplama işleri çok maliyetli.
- Öbekleme yöntemiyle kullanılan veriye yeni bakış açıları kazandırmak.
- Üzerinde çalışılan verinin gerçek hayatta kaç farklı çıktı çeşidi verebileceğini kestirememek.

2.1.3 TAKVİYELİ ÖĞRENME

Takviyeli öğrenme bir bilgisayar sisteminin bir ortamda nasıl davranması gerektiğini kontrol etmektedir. Takviyeli öğrenme ile çalışırken genellikle ödül ve ceza sistemi kullanılır. Bu sistemde öğrenme işlemi yapılırken bilgisayar sistemi tanımlanan aksiyonlardan rastgele denemeler yapar ve aldığı ödül puanının değerine göre kendi matematiksel modelini kurar. Takviyeli öğrenme özellikle oyun teorisi alanında büyük ses getirmiştir.


2.2 YAPAY SİNİR AĞLARI

Yapay sinir ağı insan beyni baz alınarak oluşturulmuş ufak algoritmalar. Bir sinir ağı girdi olarak aldığı sayıları mekanik bir sezgi, etiket veya kümeleme yöntemiyle çıktılara dönüştürür. Sinir ağlarının resimleri, sesi ve yazıları tanıyabilmesi için bu verilerin dönüştürülmesi gerekmektedir.



Şekil 1: Sinir Ağları ve Nöron Yapısı

[2] Şekil 1, bir sinir ağına örnektir. Bu ağı girdi olarak resimleri almaktadır ve mavi ile işaretlenmiş nöronlar çene yapısını ve göz yapısını ayırt edecek şekilde eğitilmiştir. Kırmızı ile gösterilen ara katman nöronları, resimden gelen veri yerine resimde bulunan özellikleri almaktadır. Örneğin bir nöron çene yapısından ve göz yapısından çıkan değerleri alıp belli bir oranda karıştırarak yüz tipi verisi oluşturabilir. Asyalı erkek için oran belirten nöron da ten rengini ve yüz tipi verisini alıp resimdeki kişinin bir asyalı erkek olma ihtimalini ortaya koyar.



Şekil 2: Nöron Karar Mekanizması

Şekil 2’de çene yapısı bir gizli nöronu %20 ve göz yapısı bu nöronu %35 etkileyebilir. Bu şekilde gizli nöron kendi kararını verebilir. Kendisine gelen verinin ırk bilgisine karar veren yeşil nöron yine aynı şekilde ağırlıklar ile gizli nöron gibi karar vererek çıktı üretir.

$$GN_{1\text{çıkıtı}} = k_1w_1 + k_2w_2 + b_1$$

Örnek Denklem 1

Örnek bir nöron çıktı hesaplaması denklem 1’de verilmiştir. B(bias) değeri nöronun sapma değeridir ve çıktıya eklenir.

$$GN_{1\text{çıkıtı}} = 0.4 * 0.2 + 0.25 * 0.35 + 0.7 = 0.8675$$

Örnek Denklem 2

Denklem 2 ‘de bir nöronun çıktısı hesaplanmıştır.

BÖLÜM III

YAPILAN ÇALIŞMALAR

3.1 UTKFACE VERİ ANALİZİ VE MODEL OLUŞTURMA

UTKFace datası kullanılarak CNN oluşturuldu ve genel karşılaştırılması sağlandı.

```
dataset_folder_name = '/content/drive/MyDrive/UTKFace'

TRAIN_TEST_SPLIT = 0.7
IM_WIDTH = IM_HEIGHT = 198

dataset_dict = {
    'race_id': {
        0: 'white',
        1: 'black',
        2: 'asian',
        3: 'indian',
        4: 'others'
    },
    'gender_id': {
        0: 'male',
        1: 'female'
    }
}
```

Şekil 3: Verilerin Tanımlanması

Teste %30, train %70 ayrıldı. Data içerisinde isimlendirme üzerinde oluşturulmuş ırk ve cinsiyet numaraları belirlendi.

```
df = parse_dataset(dataset_folder_name)
df.head()
```

Şekil 4: Dataset döndürülmesi ve gösterimi

Dataframe döndürüldü ve görüntüler yinelendi.

```
def build_race_branch(self, inputs, num_races):

    x = self.make_default_hidden_layers(inputs)

    x = Flatten()(x)
    x = Dense(128)(x)
    x = Activation("relu")(x)
    x = BatchNormalization()(x)
    x = Dropout(0.5)(x)
    x = Dense(num_races)(x)
    x = Activation("softmax", name="race_output")(x)

    return x
```

Şekil 5: Irk yapısı inşası

Yüz tanıma ile ırk dalını oluşturmak için kullanılan kod yazıldı. Irk analizinde Softmax katmanından yardım alındı. Softmax, önceki katmandan gelen değerleri olarak sınıflandırma işlemi içerisinde olasılıksal değer üretimi gerçekleştirir. Sınıflandırma yaparken hangi sınıfa daha yakın olduğuna dair değer üretir. Derin öğrenme ağı içerisinde katmanda üretilen olasılıksal değeri probalistik hesaplama gerçekleştirerek her bir sınıf için olasılık değeri ortaya koyar.

```
def build_gender_branch(self, inputs, num_genders=2):

    x = Lambda(lambda c: tf.image.rgb_to_grayscale(c))(inputs)

    x = self.make_default_hidden_layers(inputs)

    x = Flatten()(x)
    x = Dense(128)(x)
    x = Activation("relu")(x)
    x = BatchNormalization()(x)
    x = Dropout(0.5)(x)
    x = Dense(num_genders)(x)
    x = Activation("sigmoid", name="gender_output")(x)

    return x
```

Şekil 6: Cinsiyet yapısı inşası

Yüz tanıma ile cinsiyet dalını oluşturmak için kullanılan kod yazıldı. Cinsiyet analizinde Sigmoid katmanından yardım alındı. Sigmoid, en yaygın kullanılan aktivasyon fonksiyonlarından birisidir, [0,1] aralığında çıktı üretir.

```
def build_age_branch(self, inputs):  
  
    x = self.make_default_hidden_layers(inputs)  
  
    x = Flatten()(x)  
    x = Dense(128)(x)  
    x = Activation("relu")(x)  
    x = BatchNormalization()(x)  
    x = Dropout(0.5)(x)  
    x = Dense(1)(x)  
    x = Activation("linear", name="age_output")(x)  
  
    return x
```

Şekil 7: Yaş yapısı inşası

Yüz tanıma ile yaş dalını oluşturmak için kullanılan kod yazıldı. Yaş analizinde Linear katmanından yardım alındı. İki veya daha fazla değişken arasındaki ilişkinin bir doğru ile gösterilmesinden yararlanır.

```
def assemble_full_model(self, width, height, num_races):  
  
    input_shape = (height, width, 3)  
    inputs = Input(shape=input_shape)  
  
    age_branch = self.build_age_branch(inputs)  
    race_branch = self.build_race_branch(inputs, num_races)  
    gender_branch = self.build_gender_branch(inputs)  
  
    model = Model(inputs=inputs,  
                  outputs = [age_branch, race_branch, gender_branch],  
                  name="face_net")  
  
    return model
```


Şekil 8: Bileşenleri modelleme

Dosya içerisindeki fotoğrafların birden fazlasını işlemek için assemble_full_model sınıfı kullanıldı ve face_net modeli belirtildi.



Şekil 9: Oluşturulan yapının modellenmesi

UTKFace verisi içerisindeki fotoğrafların genel analizi gerçekleştirildi.



Şekil 10: Model içerisinde bulunan ırk dağılımı

Bu analize göre;

3975 tane Hintli,

3434 tane Asyalı,

10.078 tane Beyaz,

4526 tane Siyah,

1692 tane başka ırk gruplarına giren kişi vardır.




Şekil 11: Model içerisinde bulunan cinsiyet dağılımı

Bu analize göre;

12.391 tane Erkek,

11.314 tane Kadın cinsiyet gruplarına giren kişi vardır.



Şekil 12: Model içerisinde bulunan yaş dağılımı

Bu analize göre;

3062 tane 0-9 yaş aralığı,

1531 tane 10-19 yaş aralığı,

7344 tane 20-29 yaş aralığı,

4536 tane 30-39 yaş aralığı,

2245 tane 40-49 yaş aralığı,

2299 tane 50-59 yaş aralığı,

1316 tane 60-69 yaş aralığı,

699 tane 70-79 yaş aralığı,

504 tane 80-89 yaş aralığı,

137 tane 90-99 yaş aralığı,

19 tane 100-109 yaş aralığı,

13 tane tane 110-119 yaş aralığına giren kişi vardır.

Model özeti çıkarıldı ve toplam 3.192.648 tane parametre olduğu bunlardan 3.191.400 tanesinin eğitilebilir parametre, 1.248 tanesinin ise eğitilemez parametre olduğu görüldü.

```
from tensorflow.keras.optimizers import Adam

init_lr = 1e-4
epochs = 100

opt = Adam(lr=init_lr, decay=init_lr / epochs)

model.compile(optimizer=opt,
              loss={
                  'age_output': 'mse',
                  'race_output': 'categorical_crossentropy',
                  'gender_output': 'binary_crossentropy'},
              loss_weights={
                  'age_output': 4.,
                  'race_output': 1.5,
                  'gender_output': 0.1},
              metrics={
                  'age_output': 'mae',
                  'race_output': 'accuracy',
                  'gender_output': 'accuracy'})
```

Şekil 13: Model eğitimi için parametre girişi

Batch boyutu 32 ile eğitime başlandı. Model her epochtan sonra kayıt alındı ve kayıt noktası oluşturuldu ve son kayıt alındı.

```
from keras.callbacks import ModelCheckpoint

batch_size = 32
valid_batch_size = 32
train_gen = data_generator.generate_images(train_idx, is_training=True, batch_size=batch_size)
valid_gen = data_generator.generate_images(valid_idx, is_training=True, batch_size=valid_batch_size)

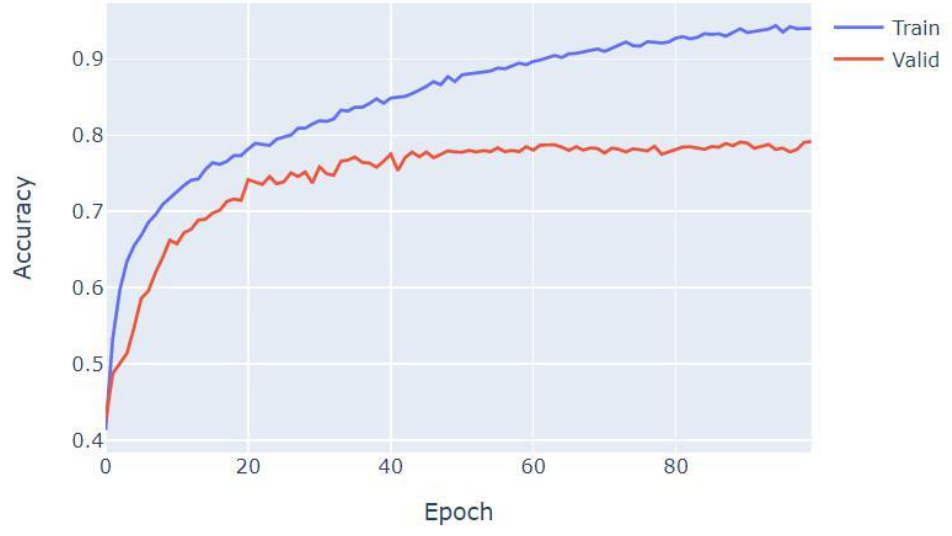
callbacks = [
    ModelCheckpoint("./model_checkpoint", monitor='val_loss')
]

history = model.fit(train_gen,
                    steps_per_epoch=len(train_idx)//batch_size,
                    epochs=epochs,
                    callbacks=callbacks,
                    validation_data=valid_gen,
                    validation_steps=len(valid_idx)//valid_batch_size)
```

Şekil 14: Model eğitimi kayıt ve epoch başlatma


Epoch tamamlandıktan sonra her bir özellik için kayıplarımızı ve doğruluk eğrileri oluşturuldu.

Etnik Kökenlerin Doğruluğu




Şekil 15: Etnik Kökenlerin Doğruluğu

Mean Absolute Error for age feature



Şekil 16: Ortalama mutlak hata (Yaş)

Genel Kayıp



Şekil 17: Genel Kayıp

```
from sklearn.metrics import classification_report  
  
cr_race = classification_report(race_true, race_pred, target_names=dataset_dict['race_alias'].keys())  
print(cr_race)
```

	precision	recall	f1-score	support
white	0.82	0.90	0.86	3007
black	0.84	0.81	0.82	1313
asian	0.81	0.82	0.82	1020
indian	0.74	0.72	0.73	1206
others	0.40	0.23	0.30	494
accuracy			0.79	7040
macro avg	0.72	0.70	0.71	7040
weighted avg	0.78	0.79	0.78	7040

Şekil 18: Irk f1-score ve accuracy değerleri

	precision	recall	f1-score	support
male	0.92	0.89	0.91	3678
female	0.89	0.92	0.90	3362
accuracy			0.90	7040
macro avg	0.90	0.91	0.90	7040
weighted avg	0.91	0.90	0.90	7040

Şekil 19: Cinsiyet f1-score ve accuracy değerleri

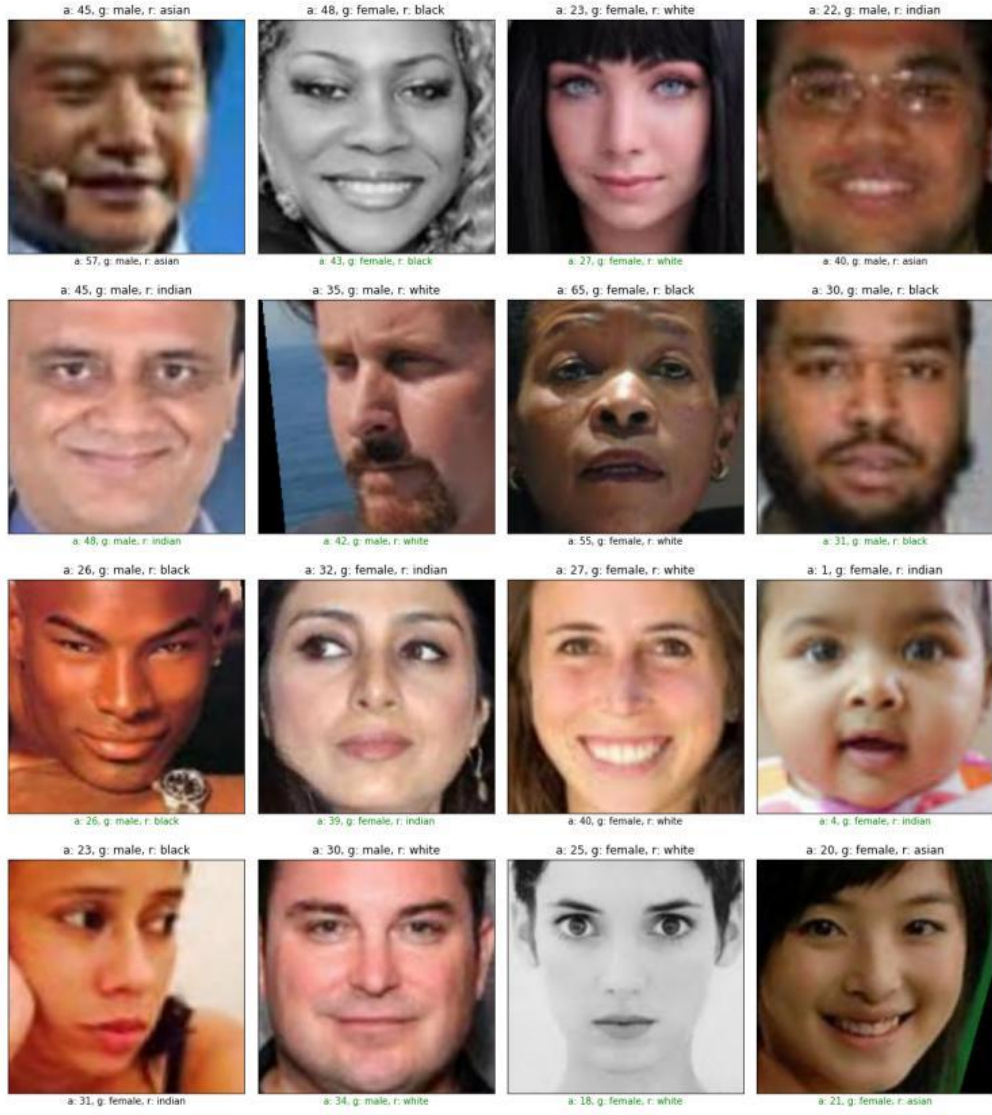
```
from sklearn.metrics import r2_score
print('R2 yas degeri: ', r2_score(age_true, age_pred))
R2 yas degeri: 0.8706210048260674
```

Şekil 20: Yaş R2 değeri

R^2 , verilerin yerleştirilmiş regresyon hattına ne kadar yakın olduğunun istatistiksel bir ölçüsüdür. Ayrıca belirleme katsayısı veya çoklu regresyon için çoklu belirleme katsayısı olarak da bilinir. R-kare, doğrusal regresyon modelleri için uygunluk ölçüsüdür.

Aynı veri seti için, daha yüksek R-kare değerleri, gözlemlenen veriler ve fit edilen değerler arasında daha küçük farkları temsil eder.

Veri seti içerisinde random 16 fotoğrafın analizi gerçekleştirildi. Gerçek değerler fotoğrafların üzerine yazdırıldı. Tahmini değerler fotoğrafın alt bölümüne yazdırıldı.



Şekil 21: Tahminlerin çalıştırılmış hali

3.2 MODELLERİN UYGULAMAYA GEÇİRİLMESİ

Yüz, yaş ve etnik köken taraması yapabilmek için öncelikle modellemeler incelendi. Bu modellemeler içerisinde [3]CAFFEModel dosyası üzerinde çalışmaya başlandı. Bir CAFFEModel dosyası, Caffe tarafından oluşturulan bir makine öğrenme modelidir. Caffe kullanılarak eğitilmiş bir görüntü sınıflandırması veya görüntü bölütleme modeli içerir. CAFFEMODEL dosyaları .PROTOTXT dosyalarından oluşturulur ve kaydı gerçekleştirilir. Caffe kullanarak modelini eğitip iyileştirdikten sonra, program kullanıcının eğitilmiş modelini bir CAFFEMODEL dosyası olarak kaydeder. Eğitilmiş görüntü sınıflandırma ve görüntü segmentasyon modelleri ile uygulamalara entegrasyonu sağlanır.

```
genderProto = "gender_deploy.prototxt"  
genderModel = "gender_net.caffemodel"
```

Şekil 22: Cinsiyet model tanımlanması

```
ageProto = "age_deploy.prototxt"  
ageModel = "age_net.caffemodel"
```

Şekil 23: Yaş model tanımlanması

```
faceNet = cv2.dnn.readNet(faceModel, faceProto)  
ageNet = cv2.dnn.readNet(ageModel, ageProto)  
genderNet = cv2.dnn.readNet(genderModel, genderProto)
```

Şekil 24: DNN (Derin Sinir Ağı) model mimarisine entegrasyonu

```
import cv2  
video = cv2.VideoCapture(0)
```

Şekil 25: OpenCV import edilmesi ve kullanımı.

Kamera ve video özelliğinden faydalanabilmek için açık kaynak kodlu OpenCV kütüphanesi kullanılmıştır. OpenCV Kütüphanesi: import cv2 yazarak kodumuza dahil ettiğimiz kütüphanedir. Tüm görüntü işleme işlemlerinde kullanılan ve bu alanın öncüsü bir kütüphanedir. OpenCV, yüzleri ve nesneleri algılama ve tanımlama, videolarda insani eylemleri sınıflandırma, kamera hareketlerini ve hareketli nesneleri izleme, nesneleri 3 boyutlu modellerine ayıklama, görüntüleri yüksek çözünürlükte birleştirme gibi alanlarda kullanılmaktadır.

```
import cv2
import math
import argparse
from deepface import DeepFace
import json
import cv2
import matplotlib.pyplot as plt
```

Şekil 26: OpenCV ve DeepFace import edilmesi

Yaş, cinsiyet ve etnik köken bilgilerinin tahmini yapılacak fotoğraf tanımlandı. Resim ön işleme için blobFromImage komutu kullanıldı.

```
blob=cv2.dnn.blobFromImage(frameOpencvDnn, 1.0,
(300, 300), [104, 117, 123], True, False)
```

Şekil 27: Resim ön işleme komutu

Model kayıtları isimlere tanımlandı.

```
faceProto="opencv_face_detector.pbtxt"
faceModel="opencv_face_detector_uint8.pb"
ageProto="age_deploy.prototxt"
ageModel="age_net.caffemodel"
genderProto="gender_deploy.prototxt"
genderModel="gender_net.caffemodel"
```

Şekil 28: Model tanımlama

Model_Mean_Values, yaş ve cinsiyet bilgilerini depolamak için 3 farklı liste oluşturuldu.

```
MODEL_MEAN_VALUES=(78.4263377603, 87.7689143744,  
114.895847746)
```

Şekil 29: Veri depolama için oluşturulmuş liste

Yaş ve cinsiyet verileri tanımlandı.

```
ageList=['(0-2)', '(4-6)', '(8-12)', '(15-  
20)', '(25-32)', '(38-43)', '(48-53)', '(60-  
100)']  
genderList=['Male', 'Female']
```

Şekil 30: Yaş ve cinsiyet aralıkları belirlenmesi

Yaş, cinsiyet ve etnik köken tahminleri ekrana yazdırıldı.

```
ageNet.setInput(blob)  
agePreds=ageNet.forward()  
age=ageList[agePreds[0].argmax()]  
print(f'Age: {age[1:-1]} years')  
  
genderNet.setInput(blob)  
genderPreds=genderNet.forward()  
gender=genderList[genderPreds[0].argmax()]  
print(f'Gender: {gender}')  
  
print(f'Race: {prediction["dominant_race"]}')
```

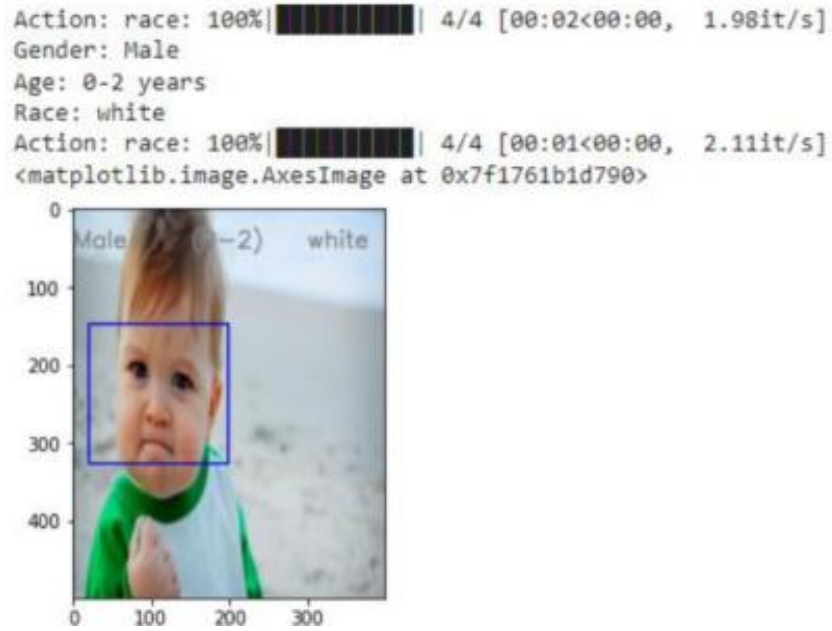
Şekil 31: Yaş, cinsiyet ve etnik köken yazdırma

Yüz saptama için haarcascade_frontalface_default.xml dosyası kullanıldı [6]. Görüntü üzerinde yaş, cinsiyet ve etnik köken bilgileri yazdırıldı.

```
cv2.putText(color_img, gender, (0, 50), font, 1,
(128,128,128), 2, cv2.LINE_4)
cv2.putText(color_img, age, (150, 50), font, 1,
(128,128,128), 2, cv2.LINE_4)
cv2.putText(color_img, prediction['dominant_race'], (300, 50),font, 1,(128,128,128), 2, cv2.LINE_4)
```

Şekil 32: Metni fotoğrafın üzerine yazdırma

Plt.imshow(color_img) komutu ile ilgili çıktı verildi.



Şekil 33: İlgili çıktının alınması

Anlık görüntü yakalaması için VideoCapture komutu kullanıldı.

```
video=cv2.VideoCapture(args.image if args.image else 0)
padding=20
while cv2.waitKey(1)<0 :
    hasFrame,frame=video.read()
    if not hasFrame:
        cv2.waitKey()
        break

    resultImg,faceBoxes=highlightFace(faceNet,frame)
    if not faceBoxes:
        print("Yuz bulunamadi")


    for faceBox in faceBoxes:
        face=frame[max(0,faceBox[1]-padding):
                    min(faceBox[3]+padding,frame.shape[0]-1),max(0,faceBox[0]-padding):
                    min(faceBox[2]+padding, frame.shape[1]-1)]

        blob=cv2.dnn.blobFromImage(face, 1.0, (227,227), MODEL_MEAN_VALUES, swapRB=False)
        genderNet.setInput(blob)
        genderPreds=genderNet.forward()
        gender=genderList[genderPreds[0].argmax()]
        print(f'Gender: {gender}')

        ageNet.setInput(blob)
        agePreds=ageNet.forward()
        age=ageList[agePreds[0].argmax()]
        print(f'Age: {age[1:-1]} years')

    cv2.putText(resultImg, f'{gender}, {age}', (faceBox[0], faceBox[1]-10), cv2.FONT_HERSHEY_SIMPLEX, 0.8,
                (0,255,255), 2, cv2.LINE_AA)
    cv2.imshow("Yas ve Cinsiyet Tarama", resultImg)
```

Şekil 34: Video görüntü yakalama kod bölümü



Şekil 35: Video görüntü yakalama çıktısı

KAYNAKLAR

- [1] A. Acien, A. Morales, R. Vera-Rodriguez, I. Bartolome ve J. Fierrez, «Measuring the Gender and Ethnicity Bias in Deep Models for Face Recognition,» Biometrics and Data Pattern Analytics (BiDA) Lab - ATVS, EPS, Universidad Autonoma de Madrid C/ Francisco Tomas y Valiente 11, 28049 Madrid, Spain.
- [2] Ufuk Serdoğan, «Yüz Parametreleri Yardımı ile İnsanların Etnik Kökenlerine Göre Sınıflandırılması», Ocak 2020, s. 4-7.
- [3] <https://www.scilab.org/deep-learning-using-caffe-model>
- [4] https://github.com/opencv/opencv/tree/master/samples/dnn/face_detector
- [5] <https://susanqq.github.io/UTKFace/>
- [6] <https://github.com/opencv/opencv/tree/master/data/haarcascades>
- [7] <https://gist.github.com/GilLevi/c9e99062283c719c03de>
- [8] <http://saucis.sakarya.edu.tr/tr/download/article-file/702151>

ÖZGEÇMİŞ VE İLETİŞİM BİLGİSİ

Efecan Demir, 2000 yılında Ankara’da doğdu. İlk, orta ve lise öğrenimini Ankara’da tamamladı. 2018 yılında girdiği Kocaeli Üniversitesi Teknoloji Fakültesi Bilişim Sistemleri Mühendisliği 4. sınıf öğrencisi olarak eğitim almaktadır.

Aziz Gültekin, 1999 yılında İstanbul’da doğdu. İlk, orta ve lise öğrenimini İstanbul’da tamamladı. 2018 yılında girdiği Kocaeli Üniversitesi Teknoloji Fakültesi Bilişim Sistemleri Mühendisliği 4. sınıf öğrencisi olarak eğitim almaktadır.

Eposta: 181307056@kocaeli.edu.tr EFECAN DEMİR

181307047@kocaeli.edu.tr AZİZ GÜLTEKİN